
Titre du mini-projet

Mini-projet : Analyse de paniers et recommandations produits Algorithmes Apriori et FP-Growth sur données réelles

1. Contexte

Une enseigne de e-commerce met à votre disposition ses données de ventes. Chaque ligne du fichier correspond à un produit vendu dans une transaction (facture). L'objectif de ce mini-projet est d'identifier des **associations d'articles** (règles du type :

Si un client achète X, ALORS il achète souvent Y)

afin de proposer des **recommandations produits** (cross-selling, bundles, agencement des rayons, etc.).

Vous utiliserez principalement :

- l'algorithme **Apriori** ;
- l'algorithme **FP-Growth** ;
- les fonctions de génération de **règles d'association** (support, confiance, lift).

2. Objectifs pédagogiques

À l'issue de ce mini-projet, l'étudiant devra être capable de :

1. **Préparer un jeu de données transactionnel** à partir de données brutes (fichiers CSV / Excel).
2. Appliquer **Apriori** et **FP-Growth** pour extraire des **itemsets fréquents** et des **règles d'association**.
3. Interpréter correctement les mesures : **support, confiance, lift**.
4. Traduire ces règles en **recommandations métier concrètes** (offres combinées, placement produits, "Vous aimerez aussi...").
5. Comparer brièvement **Apriori vs FP-Growth** (temps de calcul, nombre de règles, lisibilité).

3. Données et environnement

- Jeux de données possibles (au moins un à utiliser) :
 - `order_data.csv` : petit dataset de démonstration (quelques dizaines de transactions).

- `Online Retail.xlsx` ou `transaction_dataset.csv` : données réelles avec plusieurs milliers de transactions.
 - Environnement de travail :
 - Python (Jupyter Notebook / Google Colab),
 - Bibliothèques : `pandas`, `numpy`, `matplotlib` ou `seaborn` (optionnel), `apriori` ou `mlxtend.frequent_patterns` pour Apriori, `mlxtend.frequent_patterns` pour FP-Growth.
-

4. Travail à réaliser

Partie 0 – Mise en route (Apriori sur petit dataset)

1. Charger le fichier `order_data.csv`.
2. Construire une **liste de listes** contenant, pour chaque transaction, la liste des articles achetés.
3. Appliquer l'algorithme **Apriori** (par exemple avec `apriori`) en utilisant des paramètres proposés par l'enseignant, par exemple :
 - `min_support = 0.25`
 - `min_confidence = 0.2`
 - `min_lift = 2`
 - `min_length = 2`
4. Afficher quelques règles d'association (3 à 5 règles) et, pour **au moins deux d'entre elles** :
 - écrire la règle sous la forme : $\{X\} \Rightarrow \{Y\}$;
 - interpréter **support**, **confiance**, **lift** dans un langage simple (métier).

Objectif de la partie 0 : se remettre en tête le fonctionnement d'Apriori et le sens des métriques.

Partie 1 – Préparation des données réelles

1. À partir du fichier `Online Retail.xlsx` ou `transaction_dataset.csv` :
 - garder uniquement les colonnes utiles (par exemple : ID de facture, ID produit, quantité, éventuellement pays ou date) ;
 - nettoyer les données : suppression des valeurs manquantes, des lignes incohérentes, etc.
2. Construire le jeu de données **transactionnel** :
 - chaque transaction = une facture ;
 - chaque transaction = liste des produits achetés dans cette facture.

3. Dans le rapport, indiquer :

- **nombre total de transactions** ;
 - **nombre d'articles différents** ;
 - donner **3 exemples** de transactions (listes d'articles).
-

Partie 2 – Extraction de règles avec FP-Growth

1. Encoder les transactions :

- utiliser `TransactionEncoder` ou les fonctions de `mlxtend` pour transformer la liste de listes en tableau booléen (one-hot) ;
- obtenir un `DataFrame` dont chaque colonne correspond à un article et chaque ligne à une transaction (True/False).

2. Appliquer **FP-Growth** :

- choisir une valeur de `min_support` raisonnable (ex. 0.02 ou 0.03, à ajuster selon la taille du dataset) ;
- lister les **10 itemsets fréquents** ayant le plus grand support.

3. Générer des **règles d'association** :

- utiliser `association_rules` (`mlxtend`) avec `metric="confidence"` et une valeur de `min_threshold` (ex. 0.5 ou 0.6) ;
- trier les règles par **confiance** ou **lift**.

4. Sélectionner **5 règles intéressantes** :

- support ni trop faible ni trop élevé ;
- confiance élevée ;
- $\text{lift} > 1$ (idéalement > 1.2).

Pour chaque règle sélectionnée, vous devez :

- la réécrire en toutes lettres (ex. : « Les clients qui achètent A et B achètent souvent C ») ;
 - expliquer ce que signifient **support**, **confiance**, **lift** de cette règle ;
 - proposer **au moins une action marketing** (bundle, promotion, rangement dans le magasin, recommandation en ligne, etc.).
-

Partie 3 – Comparaison Apriori vs FP-Growth

1. Appliquer **Apriori** sur le même dataset réel (ou sur un sous-échantillon) avec des paramètres compatibles (`min_support`, etc.).

2. Comparer Apriori et FP-Growth sur :

- le **temps de calcul** (approximatif, par ex. mesure avec `%time`),
- le **nombre d'itemsets fréquents** et/ou de **règles** générées,

- la **lisibilité** des résultats (trop de règles, règles redondantes, etc.).

3. Dans la conclusion du rapport, répondre aux questions suivantes :

- Quel algorithme (Apriori ou FP-Growth) recommanderiez-vous pour ce type de données, et pourquoi ?
- Quelles sont, selon vous, les **limites** des règles d'association sur ce dataset ?
- Proposez **deux pistes d'amélioration** (segmentation par pays, par période, filtrage de certains articles, visualisation de graphes d'items, etc.).

5. Livrables attendus

1. **Un notebook Jupyter (.ipynb)** contenant :

- le code de préparation des données,
- le code Apriori,
- le code FP-Growth,
- l'extraction et la sélection des règles,
- quelques graphiques simples (facultatif) : top des produits, distribution des supports, etc.
- des **cellules Markdown** expliquant vos choix et vos résultats.

2. **Un rapport synthétique (3–4 pages)** au format PDF, comprenant :

- une **introduction** (contexte et objectif du mini-projet),
- la **méthodologie** (préparation des données, choix des paramètres, description des algorithmes utilisés),
- les **principaux résultats** (tableaux ou captures des règles retenues avec interprétation),
- des **recommandations métier** pour l'enseigne,
- une **conclusion** incluant la comparaison Apriori / FP-Growth.

2. Adaptation / enrichissement

A. Objectifs pédagogiques (version Master)

1. **Configurer et justifier les hyperparamètres** (min_support, min_confidence, métrique de tri, taille minimale/maximale des itemsets), à partir d'arguments théoriques et empiriques.

2. Mener une **analyse de sensibilité** de ces hyperparamètres sur :

- le nombre d'itemsets ;
- le type de règles obtenues ;

- l'intérêt métier des règles.
 - 3. **Segmenter** le dataset (par pays, période, type de client, etc.) et comparer les règles obtenues dans chaque segment.
 - 4. Discuter les **limites** des règles d'association (corrélation vs causalité, biais de popularité, bruit, saisonnalité, etc.).
 - 5. Proposer **une ébauche de protocole d'évaluation** si ces règles étaient utilisées dans un système de recommandation (A/B test, métriques offline...).
-

B. Extensions demandées (à ajouter à la Partie 2 ou 3)

1. Analyse de sensibilité (obligatoire)

- Faire varier `min_support` (par exemple 0.01, 0.02, 0.03, 0.05) et observer :
 - le nombre d'itemsets fréquents ;
 - le nombre de règles générées ;
 - le profil des règles (règles triviales vs règles plus rares mais plus informatives).
- Présenter les résultats dans un **tableau ou un graphique** et commenter.

2. Segmentation du dataset (obligatoire)

Sur le dataset réel, choisir un critère de segmentation (par exemple :

- un pays (UK vs autres),
- une période (haut/bas saison),
- une catégorie de produits.

Pour **au moins deux segments**, répéter :

- l'extraction d'itemsets fréquents ;
- la génération de règles d'association ;
- la sélection de 3 à 5 règles intéressantes par segment.

Dans le rapport, comparer les segments :

- Quelles règles sont communes ?
- Quelles règles sont spécifiques à un segment ?
- Quelles recommandations métier différentes peut-on proposer selon les segments ?

3. Lien avec les systèmes de recommandation (obligatoire)

Rédiger une **courte section** (~1 page) qui explique :

- comment ces règles d'association pourraient être intégrées dans un **système de recommandation** (par exemple : règles utilisées pour un module "Frequently bought together") ;

- quelles seraient les **métriques d'évaluation** pertinentes : taux de clic, taux de conversion, panier moyen, etc. ;
- quel protocole d'**expérimentation** (A/B testing, offline metrics) l'entreprise pourrait mettre en place.

4. **Discussion critique (obligatoire)** Inclure une discussion plus critique sur :

- les limites méthodologiques (corrélation vs causalité, données manquantes, biais de saison) ;
- les risques potentiels d'un mauvais usage des règles (sur-personnalisation, sur-exposition de certains produits, effets sur la diversité des ventes) ;
- des pistes de couplage avec d'autres approches (collaborative filtering, modèles séquentiels, etc.).

C. Barème indicatif

- Préparation des données et clarté du notebook : **20 %**
 - Application correcte des algorithmes (Apriori, FP-Growth) : **20 %**
 - Analyse de sensibilité et segmentation : **25 %**
 - Interprétation métier et recommandations : **20 %**
 - Qualité du rapport (structure, figures, esprit critique, bibliographie éventuelle) : **15 %**
-